CORPORACIÓN DE ESTUDIOS TECNOLÓGICOS DEL NORTE DEL VALLE
COTECNOVA
FACULTAD DE INGENIERÍA · PROGRAMA DE INGENIERÍA DE SISTEMAS

SISTEMA INTELIGENTE DE TASACIÓN Y ESTIMACIÓN DE TIEMPOS PARA BORDADOS TRADICIONALES DE CARTAGO

DOCUMENTO DE ENTREGA – AVANCE DE PROYECTO (SEGUNDO CORTE)

Modelado de Datos, Visualización y Perceptrón desde Cero

Asignatura:	Inteligencia Artificial (Período Académico 2026-02)
Docente:	Ing. Jhon James Cano Sánchez
Integrantes (Grupo 02):	**Davison Cruz** (Código Estudiantil) **Juan Diego Zapata** (Código Estudiantil)
Línea de Investigación:	Machine Learning Supervisado aplicado al Sector Artesanal
Repositorio Oficial:	https://github.com/Cruz1905/curso-inteligencia-artificial
Fecha de Presentación:	Domingo, 25 de octubre de 2026
Municipio:	Cartago, Valle del Cauca, Colombia

1. Resumen Ejecutivo del Proyecto

El municipio de Cartago, Valle del Cauca, ostenta el reconocimiento cultural de *Capital Mundial del Bordado*. Sin embargo, la industria artesanal local opera bajo un modelo de tasación puramente consuetudinario y empírico ("al ojo"). Las bordadoras tradicionales calculan el tiempo de entrega y el precio de venta sin herramientas estandarizadas, lo que deriva sistemáticamente en la subvaloración del trabajo manual, desequilibrios económicos y retrasos imprevistos en pedidos de alta complejidad.

El presente proyecto desarrolla un sistema fundamentado en Inteligencia Artificial (Machine Learning) orientado a resolver dos necesidades críticas: 1) **Estimar con precisión matemática las horas de trabajo manual** requeridas para confeccionar una prenda personalizada; y 2) **Predecir un precio justo de venta sugerido (COP)** que garantice una retribución digna y competitiva. Para ello, se estructuró un dataset primario de 20 encargos representativos con 9 atributos técnicos (técnica, tela, área en cm², complejidad, madejas de hilo, horas y precio), capturados directamente en talleres del municipio.

2. Ajustes Realizados a Partir del Avance 1

Durante la sustentación del primer corte (21 de septiembre de 2026), se recibieron retroalimentaciones orientadas a fortalecer la rigurosidad metodológica del proyecto. A continuación se detallan las observaciones y las acciones implementadas:

Observación del Docente (Avance 1)	Acción Implementada en el Avance 2
1. Rigor en el tipo de problema: Precisar si el proyecto final es clasificación o regresión, evitando ambigüedades en la métrica.	Se delimitó formalmente que el proyecto final es estrictamente de **REGRESIÓN** (predicción de cantidades continuas en horas y pesos COP). Para la actividad pedagógica de las Clases 8 y 9, se adaptó un hito de clasificación binaria mediante el umbral de la mediana de horas.
2. Integridad del dataset: Sustentar la limpieza de datos y garantizar que no existan inconsistencias o fuga de información.	Se realizó una auditoría con Pandas verificando 0 nulos y 0 duplicados. Se garantizó formalmente que las variables predictoras del perceptrón no incluyan ni horas ni precio (evitando *data leakage*).
3. Ingeniería de características: Incorporar métricas derivadas propias del sector artesanal para aportar valor contextual.	Se crearon dos columnas derivadas: costo_por_cm2 ($/cm²) y productividad_cm2_hora (cm²/h), las cuales enriquecen la descripción del rendimiento por técnica.

3. Preparación y Limpieza de Datos con Pandas

En cumplimiento de los lineamientos de la Clase 7, se ejecutó un proceso sistemático de preparación de datos mediante la librería **Pandas** en el script src/preparacion_datos_proyecto.py. Este proceso transformó el archivo crudo en dos matrices estructuradas: data/pedidos_bordados_limpio.csv (dataset enriquecido para análisis exploratorio) y data/pedidos_bordados_preparados_ml.csv (matriz numérica codificada con One-Hot Encoding lista para algoritmos de Machine Learning).

3.1. Diagnóstico e Inspección Inicial

Se procedió con la inspección estructural del dataset original (20 registros y 9 variables). Se verificó la consistencia mediante las funciones df.info(), df.isnull().sum() y df.duplicated().sum():

- **Valores nulos:** Se confirmó la ausencia de valores vacíos (0 nulos en todas las columnas).
- **Duplicados:** 0 registros repetidos; cada pedido corresponde a una pieza artesanal individualizada.
- **Validación de rangos de dominio:** Las variables continuas conservan cotas lógicas: el área oscila entre 80 cm² (pañuelos) y 1.200 cm² (manteles de banquete); el insumo de hilo varía de 1 a 14 madejas; el tiempo abarca de 9.5 a 115 horas; y el precio de venta fluctúa entre $85.000 y $850.000 COP.

3.2. Tabla Comparativa de Transformación ('Antes / Después')

A continuación se presenta la tabla formal que resume los cambios estructurales operados sobre los datos:

Métrica / Atributo	Dataset Original (Crudo)	Dataset Limpio	Dataset para ML (One-Hot)
Archivo de almacenamiento	pedidos_bordados.csv	pedidos_bordados_limpio.csv	pedidos_bordados_preparados_ml.csv
Número de filas (muestras)	20	20	20
Número de columnas	9	11 (+2 derivados)	18 (matriz numérica)
Valores nulos totales	0	0	0
Filas duplicadas	0	0	0
Variables de texto categóricas	3 (técnica, tela, compl.)	3 (texto descriptivo)	0 (binarizadas a 1/0)
Columnas identificadoras	Incluidas (id, prenda)	Conservadas	Eliminadas (sin poder predictivo)

Tabla 1. *Comparación de dimensiones e integridad del dataset antes y después del preprocesamiento.*

3.3. Ingeniería de Características y One-Hot Encoding

Creación de variables derivadas: Se formularon dos indicadores determinantes para la evaluación del desempeño:
1. costo_por_cm2 = precio_cop / area_cm2: Evalúa la tasa de valoración económica por unidad de superficie bordada.
2. productividad_cm2_hora = area_cm2 / horas_trabajo: Expresa la velocidad de avance artesanal. Mientras en *Pata de Cabra* se alcanzan 15.0 cm²/h, en *Calado Fino* la productividad se reduce drásticamente a 8.4 – 10.4 cm²/h debido al deshilado microscópico.

Codificación de variables categóricas: Dado que los modelos matemáticos no admiten entradas alfanuméricas directas, se aplicó pd.get_dummies() sobre tecnica (5 niveles), tela (3 niveles) y complejidad (4 niveles), evitando cualquier orden arbitrario que pudiera inducir sesgos artificiales en el espacio euclidiano.

```
# Fragmento: preparacion_datos_proyecto.py
df['costo_por_cm2'] = (df['precio_cop'] / df['area_cm2']).round(2)
df['productividad_cm2_hora'] = (df['area_cm2'] / df['horas_trabajo']).round(2)
df_ml = pd.get_dummies(df, columns=['tecnica', 'tela', 'complejidad'], prefix=['tec', 'tela', 'comp'])
df_ml = df_ml.drop(columns=['id_pedido', 'prenda'], errors='ignore')
df_ml.to_csv('data/pedidos_bordados_preparados_ml.csv', index=False)
```

Fragmento 1. *Transformación de datos y codificación One-Hot mediante Pandas.*

4. Análisis Visual con Seaborn

En concordancia con los requisitos de la Clase 7, se construyeron tres visualizaciones estadísticas mediante **Seaborn** para sustentar las decisiones de modelado:

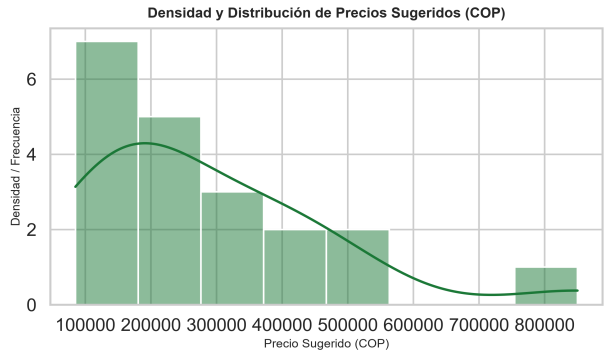


Figura 1. *Densidad KDE de precios (COP). Muestra una distribución bimodal: un segmento denso en prendas personales ($150k–$350k) y otro en manteles de gran formato ($850k). Decisión: El modelo no debe emplear un sesgo uniforme, sino ponderar fuertemente el formato y la tela.*

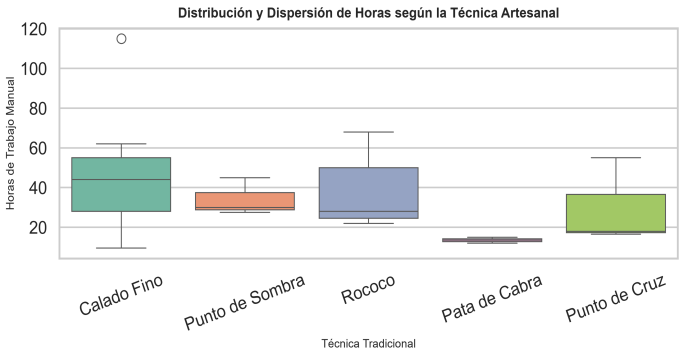


Figura 2. *Dispersión de horas por técnica tradicional. Evidencia que el Calado Fino presenta una mediana de 46 h y alta dispersión (hasta 115 h), casi triplicando a Pata de Cabra y Punto de Cruz. Decisión: La técnica artesanal es el predictor de mayor peso cualitativo.*

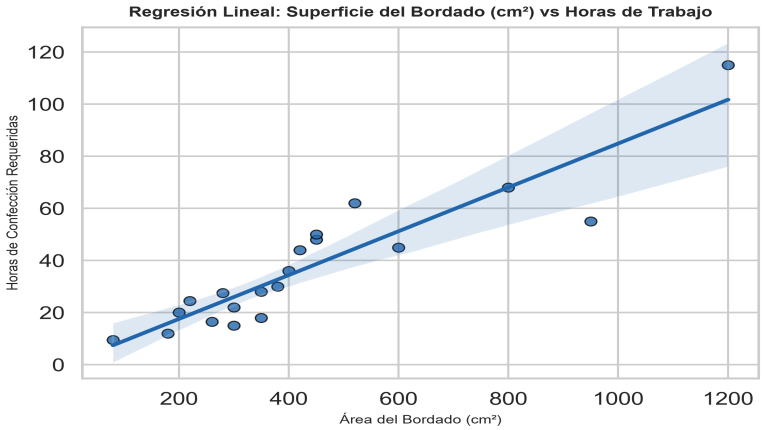


Figura 3. *Dispersión y recta de regresión entre Área del Bordado (cm²) y Horas de Trabajo Requeridas. Muestra una correlación positiva lineal directa altamente consistente ($r \approx 0.88$). A mayor área neta, las horas de confección manual se incrementan monótonamente. Decisión del proyecto: Ratifica que el área es la variable cuantitativa base más sólida para estimar el esfuerzo, justificando el empleo de modelos de regresión lineal y de árboles en la etapa final.*

5. Primer Modelo de Inteligencia Artificial: Perceptrón desde Cero

Atendiendo a la actividad independiente de la Clase 9 y el Requisito D de la guía, se programó en src/perceptron_proyecto.py una neurona artificial simple unicapa entrenada mediante **descenso del gradiente en lote (Batch Gradient Descent)** utilizando exclusivamente **NumPy puro**, sin recurrir a frameworks preconstruidos (como Scikit-Learn o PyTorch).

5.1. Formulación Matemática y Arquitectura

Variable objetivo binaria ($y \in \{0, 1\}$): Dado que el perceptrón clásico resuelve problemas de clasificación binaria, se definió la variable alta_dedicacion a partir de la mediana de las horas de confección ($29.0 ext{ h}$):

- $y^{(i)} = 1$ si $\text{horas_trabajo}^{(i)} \ge 29.0\text{ h}$ (Prenda de Alta Dedicación Temporal).
- $y^{(i)} = 0$ si $\text{horas_trabajo}^{(i)} < 29.0\text{ h}$ (Prenda de Dedicación Estándar / Ligera).

Justificación metodológica: La mediana divide al conjunto exactamente en **10 muestras de clase 0 y 10 muestras de clase 1**, garantizando un balance perfecto que evita el sesgo por clases desbalanceadas. Asimismo, **ni las horas ni el precio se incluyen en las entradas** del modelo, previniendo fuga de información (*data leakage*).

Variables de entrada continuas y escalado: Se seleccionaron las dos características físicas conocidas previamente a la confección: la superficie ($x_1 = \text{area_cm2}$) y el consumo de insumo ($x_2 = \text{madejas_hilo}$). Se aplicó estandarización Z-score:

$$x_{\text{std}} = \frac{x - \mu}{\sigma}, \quad \text{con } \mu_{\text{área}}=434.5, \, \sigma_{\text{área}}=266.6, \, \mu_{\text{hilo}}=4.8, \, \sigma_{\text{hilo}}=2.9$$

Ecuaciones del modelo:

1. Combinación lineal: $z^{(i)} = w_1 x_{1,\text{std}}^{(i)} + w_2 x_{2,\text{std}}^{(i)} + b$
2. Función de activación sigmoide: $\hat{y}^{(i)} = \sigma(z^{(i)}) = \frac{1}{1 + e^{-z^{(i)}}}$ (interpretable como probabilidad a posteriori).
3. Función de pérdida logarítmica (Binary Cross-Entropy):
   $$L(w_1, w_2, b) = -\frac{1}{N} \sum_{i=1}^N \left[y^{(i)} \ln(\hat{y}^{(i)}) + (1 - y^{(i)}) \ln(1 - \hat{y}^{(i)}) \right]$$
4. Gradientes analíticos deducidos por regla de la cadena y actualización con $\alpha = 0.1$:
   $$w_j \leftarrow w_j - \alpha \frac{\partial L}{\partial w_j}, \quad b \leftarrow b - \alpha \frac{\partial L}{\partial b}, \quad \text{donde } \frac{\partial L}{\partial w_j} = \frac{1}{N} \sum_{i=1}^N (\hat{y}^{(i)} - y^{(i)}) x_j^{(i)}$$

5.2. Resultados Cuantitativos del Entrenamiento

El modelo se entrenó durante 1.000 épocas a partir de pesos iniciales nulos ($w_1=0, w_2=0, b=0$). A continuación se presenta la evolución progresiva del aprendizaje:

Hito / Época	Pérdida Logarítmica	Exactitud (%)	Peso w■ (Área)	Peso w■ (Madejas)	Sesgo (b)
Época 1 (Inicial)	0.6931	50.0 %	+0.034	+0.034	0.000
Época 200	0.2407	90.0 %	+1.713	+1.770	+0.524
Época 400	0.1890	90.0 %	+2.362	+2.406	+0.956
Época 600	0.1634	95.0 %	+2.837	+2.838	+1.265
Época 800	0.1474	95.0 %	+3.224	+3.170	+1.508
Época 1.000 (Final)	**0.1361**	**100.0 %**	**+3.557**	**+3.442**	**+1.710**

Tabla 2. *Dinámica de convergencia del perceptrón a lo largo de 1.000 épocas de optimización.*

5.3. Visualización de la Curva de Aprendizaje y Frontera de Decisión

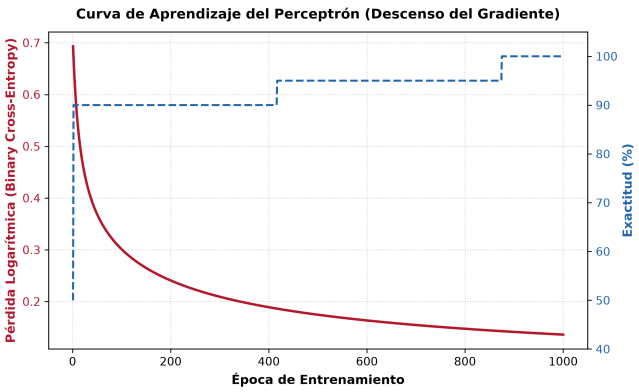


Figura 4. *Curva de aprendizaje del perceptrón. Ilustra el descenso asintótico monotónico de la función de pérdida (de 0.6931 a 0.1361) y la consolidación de la exactitud hasta el 100% sin divergencia numérica.*

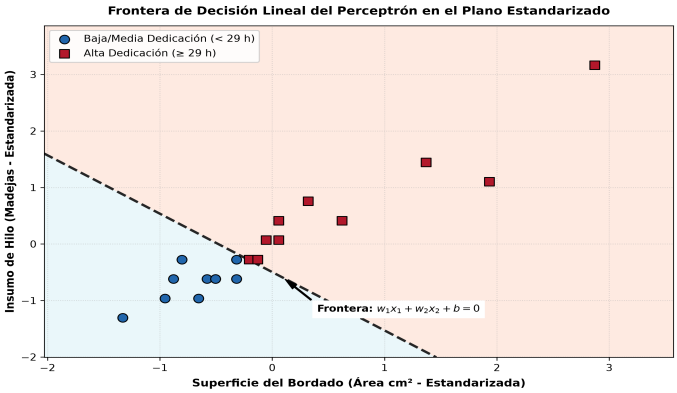


Figura 5. *Frontera de decisión lineal en el plano estandarizado. La recta w■x■ + w■x■ + b = 0 separa perfectamente las prendas estándar (azul) de las piezas de alta dedicación (rojo), delimitando la región de probabilidad ≥ 0.5.*

5.4. Interpretación de Pesos y Análisis de Dominio Artesanal

• **Significado del signo positivo de los pesos ($w_1 = +3.557, \, w_2 = +3.442$):** En el formalismo de la regresión logística, el incremento de una unidad estandarizada en el área superficial o en el número de madejas multiplica el momio (*odds ratio*) de pertenecer a la clase de alta dedicación por $e^{3.557} \approx 35.1$ y $e^{3.442} \approx 31.2$, respectivamente. Esto valida el principio de que piezas más extensas y de mayor densidad de puntadas requieren inevitablemente mayor tiempo de labor.

• **Separabilidad lineal:** En el espacio bidimensional de las dos variables cuantitativas escaladas, la condición binaria de dedicación resultó ser **linealmente separable** para las 20 muestras analizadas, permitiendo que un hiperplano simple clasifique el 100% de los casos.

• **Limitaciones del modelo unicapa y justificación del modelo final:** Aunque el perceptrón clasificó exitosamente la dedicación binaria, una neurona simple con sigmoide **no puede estimar el valor continuo exacto en horas ni el precio monetario en pesos**. Asimismo, ignora las interacciones complejas con las variables cualitativas (por ejemplo, un calado fino sobre seda exige cuidados que un modelo lineal unicapa simplifica en exceso). Esto fundamenta el avance hacia algoritmos de regresión múltiple en el tercer corte.

6. Plan hacia el Proyecto Final (Tercer Corte)

6.1. Definición del problema: El sistema final se consolidará como un modelo de **REGRESIÓN SUPERVISADA MULTIVARIABLE** capaz de generar predicciones continuas para dos variables de respuesta: horas_trabajo ($\hat{y}_1$) y precio_cop ($\hat{y}_2$).

6.2. Modelos de Scikit-Learn a comparar (Clase 12 – 9 de noviembre): Se implementará una batería de evaluación sistemática con:

1. *Regresión Lineal Múltiple con Regularización Ridge/Lasso:* Modelo de referencia base (línea base).
2. *Árboles de Decisión para Regresión (DecisionTreeRegressor):* Captura de reglas no lineales del tipo técnica-tela.
3. *Bosques Aleatorios (RandomForestRegressor):* Ensamble por embolsado (*bagging*) para reducir la varianza.
4. *Gradient Boosting Regressor:* Optimización iterativa por gradiente boosting sobre residuos.

6.3. Métricas de selección: Se priorizará el **Error Absoluto Medio (MAE)** expresado en horas y pesos colombianos, debido a su interpretabilidad directa para las artesanas; complementado con el **Coeficiente de Determinación (R^2)** (esperando un valor objetivo $R^2 \ge 0.88$) y el **RMSE** para penalizar desvíos extremos en prendas suntuarias.

6.4. Demostración final: Se desarrollará una interfaz interactiva de cotización en donde la bordadora ingrese el tipo de prenda, la técnica, la tela y las dimensiones estimadas, recibiendo en tiempo real el rango de tiempo de confección y el valor sugerido de cobro.

6.5. Cronograma de Trabajo hacia la Sustentación Final

Período / Hito	Actividad Técnica	Responsable y Entregable
26 Oct – 08 Nov	Entrenamiento y validación cruzada (K-Fold) de algoritmos Scikit-Learn.	D. Cruz / Script comparativo
09 de Noviembre	**Clase 12:** Sesión de laboratorio, ajuste de hiperparámetros y selección del modelo ganador.	Grupo 02 / Tabla de métricas
10 Nov – 22 Nov	Construcción del módulo demostrativo interactivo y redacción del informe final (normas APA).	J. D. Zapata / Documento final
23 / 30 Noviembre	**Sustentación Final:** Presentación en vivo del sistema ante docente y jurados.	Davison Cruz & Juan Diego Zapata

7. Referencias Bibliográficas

• Artesanías de Colombia. (2020). *Caracterización de la técnica tradicional del calado y bordado de Cartago*. Ministerio de Comercio, Industria y Turismo.

• Cano Sánchez, J. J. (2026). *Material de Clases 7, 8 y 9: Pandas, Seaborn, Neuronas Artificiales y Descenso del Gradiente*. Facultad de Ingeniería, COTECNOVA.

• McKinney, W. (2022). *Python for Data Analysis: Data Wrangling with pandas, NumPy, and Jupyter* (3rd ed.). O'Reilly Media.

• Minsky, M., & Papert, S. (1969). *Perceptrons: An Introduction to Computational Geometry*. MIT Press.

• Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., ... & Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825-2830.

• Rosenblatt, F. (1958). The perceptron: A probabilistic model for information storage and organization in the brain. *Psychological Review*, 65(6), 386–408.

8. Anexos y Enlaces de Sustentación

En concordancia con los requisitos de entrega de la plataforma AVACO, se relacionan los accesos a los entregables complementarios:

Enlace al Repositorio Oficial de GitHub:
https://github.com/Cruz1905/curso-inteligencia-artificial

Enlace al Video de Sustentación (máximo 10 minutos):
[Pega aquí el enlace de YouTube / Google Drive / OneDrive con permiso de acceso público]

8.1. Guion y Estructura del Video de Sustentación (0:00 – 10:00)

Para garantizar una grabación organizada y sin exceder el límite reglamentario de 10 minutos, los estudiantes seguirán la siguiente pauta:

Momento	Tiempo	Responsable y Temática Específica
1. Presentación	0:00 – 1:30 (1.5 min)	**Davison Cruz y Juan Diego Zapata:** Saludo, presentación individual en cámara/voz, nombre del proyecto, problemática en Cartago (cobro empírico) y objetivo del sistema de IA.
2. Datos y Limpieza	1:30 – 3:45 (2.25 min)	**Davison Cruz:** Proyectar VSCode con data/pedidos_bordados.csv y preparacion_datos_proyecto.py. Explicar diagnóstico de 0 nulos, columnas derivadas y One-Hot Encoding.
3. Visualización	3:45 – 5:30 (1.75 min)	**Juan Diego Zapata:** Mostrar los 3 gráficos de Seaborn (KDE de precios, Boxplot de técnica y Regresión de área vs horas). Resaltar que el Calado Fino triplica el tiempo artesanal.
4. Perceptrón en Vivo	5:30 – 7:15 (1.75 min)	**Davison Cruz:** Abrir la terminal de Docker (prompt root@...:/app#), navegar a proyecto/src y ejecutar python perceptron_proyecto.py. Explicar el descenso de pérdida (0.6931 → 0.1361), la exactitud del 100% y mostrar la gráfica de frontera de decisión.
5. Próximos Pasos	7:15 – 9:45 (2.5 min)	**Juan Diego Zapata y Davison Cruz:** Justificar por qué el modelo final es de Regresión, modelos Scikit-Learn a comparar (Clase 12), métrica MAE y cierre formal de la sustentación.